

Continual Learning Implementation

Paper: iCaRL - Incremental Classifier and Representation Learning

Experimental Setup

모델 구조

ResNet-32:

- 1. CIFAR-10과 CIFAR-100 모두 수정된 ResNet-32를 기본 특징 추출기로 사용.
- 2. layer1, layer2, layer3의 3개 합성곱 층으로 구성되며, Batch Normalization과 ReLU 활성화 함수로 구성된 BasicBlock을 포함.

IncrementalNet:

- 1. 학습된 전체 클래스 수에 따라 동적으로 조정되는 Fully Connected Layer 포함.
- 2. 새로운 클래스가 추가되면 출력 계층이 자동으로 업데이트.

학습 프레임워크 iCaRL:

- 1. 리허설 메모리: 이전에 학습한 클래스를 대표하는 샘플을 저장하여 새 클래스를 학습할 때도 반복 학습 가능.
- 2. 지식 증류: 이전 모델의 출력을 현재 모델과 비교하여 이전 클래스 지식을 유지.

데이터셋



- CIFAR-10:
 - 10개의 클래스로 구성된 비교적 간단한 데이터셋.
 - 클래스 수가 적어 망각 문제와 메모리 관리의 도전 과제가 낮음.
- CIFAR-100:
 - 100개의 클래스로 구성된 다중 클래스 데이터셋.
 - 클래스 수가 많아 메모리 관리 및 성능 유지에 더 큰 도전 과제를 제공.

하이퍼파라미터 설정

항목	CIFAR-10	CIFAR-100
초기 학습률	0.1	0.1
초기 학습 에포크	20	20
학습률 감소 단계	[60, 120, 170]	[60, 120, 170]
가중치 감소	0.0005	0.0005
배치 크기	[32, 64, 128, 256]	[32, 64, 128, 256]
메모리 예산	[500, 1000, 1500, 2000]	[500, 1000, 1500, 2000]
EXEMPLAR 크기	[10, 20, 50, 100, 200]	[10, 20, 50, 100, 200]
온도 매개변수(T)	2	2
CLASS INCREMENT	[10, 20]	[10, 20, 25, 50]

실험 결과 및 분석

Memory Budget에 따른 테스트 정확도



좌 : CIFAR10 우: CIFAR100


CIFAR-10

- 그래프 분석:
 - 메모리 예산이 500에서 1000으로 증가할 때 정확도가 약간 상승(89%).
 - 그러나, 1000 이상에서는 정확도가 급격히 감소(87.8%).
- 특징:
 - 수익 체감 현상이 뚜렷하며, 과도한 메모리 할당이 새로운 클래스 학습을 방해.
 - 적정 메모리 예산은 약 1000으로 추정.

CIFAR-100

- 그래프 분석:
 - 메모리 예산이 500에서 가장 높은 정확도(62%)를 기록.
 - 그러나, 1000에서는 급격히 감소(58%).
 - 이후, 1500에서 성능이 회복되지만 다시 하락(2000에서 59%).
- 특징:
 - 초기 메모리 예산(500)이 최적의 성능을 제공.
 - 메모리 예산이 늘어날수록 성능의 회복은 제한적이며, 과도한 예산은 새로운 클래스 학습을 저해.

Exemplar 크기에 따른 테스트 정확도



좌 : CIFAR10 우: CIFAR100

CIFAR-10


- 그래프 분석:
 - 메모리 예산이 500에서 1000으로 증가할 때 정확도가 약간 상승(89%).
 - 그러나, 1000 이상에서는 정확도가 급격히 감소(87.8%).
- 특징:
 - 수익 체감 현상이 뚜렷하며, 과도한 메모리 할당이 새로운 클래스 학습을 방해.
 - 적정 메모리 예산은 약 1000으로 추정.

CIFAR-100

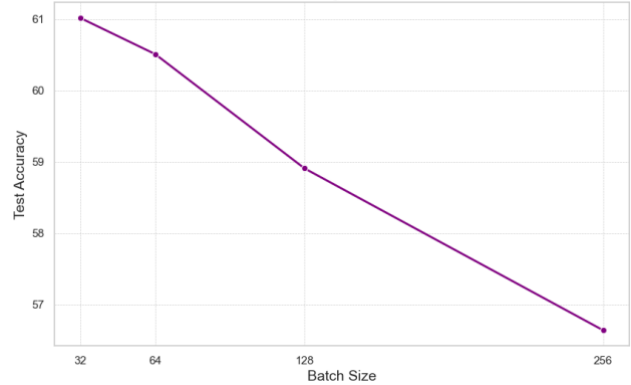
- 그래프 분석:
 - Exemplar 크기가 10에서 20으로 증가할 때 정확도가 큰 폭으로 상승(57.5% → 60%).
 - 이후 Exemplar 크기가 증가할수록 성능은 점진적으로 상승.
 - Exemplar 크기가 200일 때 가장 높은 정확도(61.5%)를 기록.
- 특징:
 - Exemplar 크기가 클수록 정확도가 꾸준히 향상.
 - 클래스 수가 많아 적은 Exemplar 크기(10~20)에서는 성능이 제한적.
 - 큰 Exemplar 크기(200)는 충분한 클래스를 학습하도록 도와줌.

Batch Size에 따른 테스트 정확도

Batch Size에 따른 평균 Test Accuracy 변화



Test Accuracy vs Batch Size



좌 : CIFAR10 우: CIFAR100




CIFAR-10

- 그래프 분석:
 - 작은 배치 크기(32)에서 가장 높은 정확도(89.5%).
 - 배치 크기가 증가할수록 정확도가 감소.
 - 배치 크기 256에서 가장 낮은 정확도(87.5%) 기록.
- 특징:
 - 작은 배치 크기(32~64)는 모델이 더 자주 업데이트되므로 더 세밀한 학습 가능.
 - 큰 배치 크기는 모델 업데이트 횟수를 줄여 이전 클래스 정보 망각 증가.





CIFAR-100

- 그래프 분석:
 - 작은 배치 크기(32)에서 가장 높은 정확도(61%).
 - 배치 크기가 증가할수록 정확도는 꾸준히 감소.
 - 배치 크기 256에서 가장 낮은 정확도(57%)를 기록.
- 특징:
 - CIFAR-100에서도 작은 배치 크기(32~64)가 더 높은 성능을 제공.
 - 클래스 수가 많음에도 불구하고, 배치 크기의 증가가 성능에 긍정적인 영향을 미치지 않음.
 - 큰 배치 크기는 이전 클래스 정보 망각을 가속화할 가능성이 높음.

Class Increment에 따른 테스트 정확도



CIFAR10



CIFAR100

- CIFAR-10은 클래스 수가 적기 때문에 메모리 예산, Exemplar 크기, Batch Size와 같은 변수에 덜 민감하며, 적은 자원으로도 높은 성능을 유지할 수 있음.
- 반면, CIFAR-100은 클래스 수가 많아 클래스 증분(Class Increment)에 따른 성능 감소가 더 뚜렷하며, 이를 완화하기 위해 더 큰 Memory Budget과 Exemplar Size가 필수적임.
- 두 데이터셋 모두 작은 Batch Size(32~64)와 낮은 Temperature($T=2$)가 최적의 성능 유지에 유리하며, 이러한 설정은 클래스 간 차이를 명확히 유지하는 데 중요한 역할을 함.
- CIFAR-100은 클래스 수의 증가로 인해 메모리 관리와 하이퍼파라미터 최적화가 더 세밀하게 요구되며, 클래스 증가 문제를 해결하기 위해 추가적인 리허설 메모리 전략이나 지식 증류 방법을 고려해야 함.